

Pipeline HTR : CV + NLP pour la transcription automatique de manuscrits médiévaux français

Master Data/IA — Module Vision par ordinateur & NLP — HETIC 2026

GitHub : <https://github.com/ourariTinhinane/htr-medieval-manuscripts-2026>

HuggingFace-CV : <https://huggingface.co/TinhinaneO/trocr-medieval-french-2026>

HuggingFace-NLP : <https://huggingface.co/TinhinaneO/camembert-ner-medieval-french-2026>

Auteurs : S.Belmiloud, T.Ourari, L.Attouche, R.Ben mansour

Résumé — Nous présentons un pipeline complet HTR ; CV + NLP pour la transcription automatique de manuscrits médiévaux en vieux et moyen français (XIIIe–XVe s.). TrOCR fine-tuné sur 59 640 lignes (CREMMA, GalliCorpora, Fabliaux) atteint CER 5,62 % et IC [95 % : 4,83–6,48 %] sur 5 419 lignes de test, dépassant le seuil d'excellence de 8 %. Le volet NLP applique normalisation par règles paléographiques, correction MLM (CamemBERT), NER par gazetier + LoRA, POS (stanza), extraction de relations et export TEI-XML. Une analyse comparative sur 5 pages Gallica inédites quantifie l'écart $\times 26$ de difficulté entre écriture littéraire (gothique textura) et administrative (cursive abrégée).

1. Introduction

En 2026, la BnF recense 380 000 manuscrits dont 11 millions accessibles via Gallica. Malgré cette numérisation massive, l'image numérique n'est pas un texte interrogeable. La transcription manuelle (~ 50 €/h) ne peut passer à l'échelle. Ce projet développe un pipeline reproductible de bout en bout : Volet 1 (CV) produit les transcriptions ; Volet 2 (NLP) les normalise, les annote et les exporte en TEI-XML. Les contributions : (1) TrOCR fine-tuné, CER 5,62 % ; (2) pipeline NLP complet ; (3) analyse littéraire vs. administratif sur 5 pages Gallica inédites ; (4) publication HuggingFace + GitHub documenté.

2. État de l'art

HTR. Kraken [1] (LSTM + CTC) est adopté dans les humanités numériques via eScriptorium/HTR-United. TrOCR [2] (ViT + RoBERTa) atteint l'état de l'art sur plusieurs benchmarks. Nous choisissons TrOCR pour son intégration HuggingFace native et son architecture Transformer plus expressive.

NLP médiéval. CamemBERT [3] (français moderne) sert de base. Les modèles spécialisés (pjox/dalembert-classical-fr-ner) offrent un meilleur point de départ pour le moyen français. LoRA [4] ($r=8$) permet un fine-tuning efficace avec peu de données annotées. L'export TEI-XML est le standard des humanités numériques pour l'interopérabilité.

3. Données

3.1 Corpus HTR

Corpus	Période	Lignes
CREMMA Medieval	XIIIe–XVe	45 696
GalliCorpora XVe	XVe	2 070
Fabliaux	XIIIe–XIVe	11 874
TOTAL		59 640

Split 80/10/10 par document (pas par ligne). Test set scellé SHA-256 avant tout développement.

3.2 Pages Gallica inédites

Cinq pages sans vérité terrain : 3 littéraires (gothique textura soignée, btv1b55013464t + btv1b8449691v) et 2 administratives (cursive gothique abrégée, btv1b90604893). Ce contraste délibéré permet une analyse comparative quantitative des performances.

3.3 Convention & biais

Semi-diplomatique : abréviations développées ($\tilde{q} \rightarrow$ que, $p \rightarrow$ par), orthographe médiévale conservée (cheualiers reste cheualiers). Biais identifiés : sur-représentation XIVE–XVe, absence de latin/langues d'oc, ratio littéraire/administratif 3,5:1.

4. Méthodes

4.1 Volet 1 — Pipeline CV

Prétraitement : (1) conversion niveaux de gris ; (2) deskewing Hough (threshold=200, médiane des angles) ; (3) CLAHE (clipLimit=2.0, tile=8 $\times$ 8) ; (4) binarisation Sauvola (window=25). CLAHE puis Sauvola : CLAHE améliore le contraste localement avant que Sauvola calcule son seuil adaptatif — supérieur à Otsu de 5–10 pts CER sur parchemin irrégulier.

Segmentation : YOLO biglam/medieval-manuscript-yolov11n (CATMuS Medieval Segmentation). Préféré à SAM (crash RAM Colab sur images haute résolution). Détecte MainZone, MarginTextZone, GraphicZone avec ordre de lecture bi-colonne.



[Fig. 1 — Exemples prétraitement : image brute $\rightarrow$ niveaux de gris $\rightarrow$ CLAHE $\rightarrow$ Sauvola]

Fine-tuning TrOCR : microsoft/trocr-base-handwritten, 5 epochs, $lr=5 \times 10^{-5}$, batch=4, warmup=500, seed=42. Seq2SeqTrainer HuggingFace. Fine-tuning complet.

4.2 Volet 2 — Pipeline NLP

Normalisation par règles : 7 règles déterministes : tilde nasal ($gr\tilde{a}t \rightarrow grant$), $\tilde{q} \rightarrow que$, $g \rightarrow con/com$, $p \rightarrow par$, $7 \rightarrow et$, u/v , i/j . CER relatif mesure l'apport sans vérité terrain.

Correction MLM : CamemBERT masque les tokens $conf < 0,70$ et choisit le candidat maximisant $P(token|contexte)$. Limitation OOV : CamemBERT ne connaît pas le vocabulaire médiéval.

NER : Gazetier (PER : mabile, tiece, fouchier ; TITLE : dame, sire) + CamemBERT-LoRA ($r=8$, $\alpha=16$, 15 epochs, $lr=2 \times 10^{-4}$). Schéma BIO, alignement first-token (-100 sur sous-tokens de continuation).

Relations & graphe : Co-occurrence avec contrainte de proximité. Triplets : (PER, porte_titre, TITLE), (PER,

5. Résultats

Métrique	Baseline	Notre modèle	Seuil excel.
CER ↓	13,77 %	5,62 % ✓	< 8 %
WER ↓	42,41 %	15,46 % ✓	< 15 %
Needs review ↓	16,2 %	3,6 % ✓	< 20 %
IC 95 %	—	[4,83–6,48 %]	—

5.2 Normalisation & correction MLM

Étape	Littéraire	Administratif
CER relatif brut→norm.	~1-2 %	~4-6 %
CER relatif norm.→MLM	0,25 %	6,49 %
Lignes corrigées MLM	~15 %	~40 %

5.3 NER & relations

5.4 Analyse littéraire vs. administratif

Dimension	Littéraire	Administratif
Confiance HTR moy.	~0,85–0,90	~0,60–0,70
Taux needs_review	~5–10 %	~35–45 %
CER relatif MLM	0,25 %	6,49 % (×26)

Le pipeline performe significativement mieux sur les textes littéraires que administratifs, reflet direct du biais 3,5:1 dans le corpus d'entraînement. Limitations techniques : pie-

7. Conclusion

Modèles publiés sur HuggingFace :

- GitHub documenté avec tests pytest pour reproductibilité complète.

[1] Kiessling et al. (2019). eScriptorium. ICDAR Workshop.

- [2] Li et al. (2021). TrOCR. arXiv:2109.10282.
- [3] Martin et al. (2020). CamemBERT. ACL.
- [4] Hu et al. (2021). LoRA. arXiv:2106.09685.
- [5] Pinche et al. (2022). CREMMA Medieval. HTR-United.
- [6] CATMuS Medieval. (2024). HuggingFace Datasets.