




Projet MD5 (Volets CV + NLP)

Traitement automatique de manuscrits anciens

Groupe :

- BELMILOUD Sarah
- OURARI Tinhinane
- BEN MANSOUR Ryma
- ATTOUCHE Licia

2025 – 2026

Contexte


Deux mondes, un pipeline

Au 15e siècle, deux pratiques de l'écrit coexistent en français médiéval : d'un côté des manuscrits **littéraires soignés**, de l'autre des actes **administratifs** rédigés à toute vitesse, couverts d'abréviations. Deux styles graphiques radicalement opposés ,un vrai défi pour la reconnaissance automatique.

L'objectif

Construire, évaluer et comparer un système HTR + NLP capable de traiter cette diversité, de l'image brute jusqu'à l'extraction de relations sémantiques.

	CREMMA Medieval	GalliCorpora XVe
Style	Gothique textura soignée	Cursive gothique abrégé
Usage	Administratif	Administratif



Volet 1 - CV

Corpus & Données

Corpus	Période	Langue	Licence	Fichiers	Lignes
CREMMA Medieval	XIIIe – XVe s. (13 ^e - 15)	Vieux/Moyen français	CC-BY	558 fichiers	45696 lignes
GalliCorpora XVe	XVe s. (15 ^e)	Moyen français	CC-BY	25 fichiers	2070 lignes
Fabliaux médiévaux	XIIIe – XIVe s. (13 ^e - 14)	Vieux français	CC-BY	181 fichiers	11874 lignes

TOTAL : 59640 lignes

Train/Val/Test
80/10/10

Train : 46657 lignes (81.2%)
Val : 5239 lignes (9.1%)
Test : 5580 lignes (9.7%)

SHA – 256
test set scellé

Approche semi-diplomatique : orthographe médiévale conservée (héritée des corpus CREMMA, GalliCorpora, Fabliaux)

Pipeline de Prétraitement

1

Niveaux de gris

Conversion
BGR → Gray
Réduction
dimensionnelle

2

Deskewing

Détection
Hough
Correction
inclinaison

3

CLAHE

Amélioration
contraste
Local adaptatif


4

Sauvola

Binarisation
adaptative
Meilleure que
seuil global

=== FABLIAUX ===

1. Originale



Source gallica.bnf.fr / Bibliothèque nationale de France, Département des Manuscrits, Français 507


2. Niveaux de gris



Source gallica.bnf.fr / Bibliothèque nationale de France, Département des Manuscrits, Français 507


Pipeline de prétraitement
Angle corrigé : 0.00°

3. Redressée



Source gallica.bnf.fr / Bibliothèque nationale de France, Département des Manuscrits, Français 507

4. Contraste CLAHE



Source gallica.bnf.fr / Bibliothèque nationale de France, Département des Manuscrits, Français 507

5. Binarisée (Sauvola)



Source gallica.bnf.fr / Bibliothèque nationale de France, Département des Manuscrits, Français 507

Segmentation

- **YOLO biglam/medieval-manuscript-yolov11n entraîné sur CATMuS Medieval** (HaggingFace)
- Ordre de lecture bi-colonne respecté

SAM vs YOLO biglam

	SAM	YOLO biglam
Entraînement	Généraliste :fonctionne sur tout	Spécialisé manuscrits médiévaux (CATMuS)
Ce qu'il détecte	Toutes les régions visuellement distinctes	Les classes définies : MainZone, MarginTextZone...
Précision sur manuscrits	Moyenne : ne connaît pas les manuscrits	Meilleure : entraîné sur ce type de document
Vitesse	Lent (lourd en RAM)	Rapide
Résultat	Trop de régions, mauvaise classification	Classes directement utiles

Modèle HTR — Fine-tuning TrOCR

microsoft/trocr-base-handwritten

Encoder ViT (vision) + Decoder RoBERTa

Hyperparamètres

epochs : 5

seed : 42

Batch size : 4

eval : par epoch

Learning rate : 5×10^{-5}

Pourquoi TrOCR ?

- Architecture encoder-decoder adaptée aux séquences variables
- Pré-entraîné sur manuscrits (trocr-base-handwritten)
- Fine-tuning rapide
- Intégration native HuggingFace Transformers
- Résultats état de l'art sur HTR médiéval

Résultats Quantitatifs

Métrique	Baseline (sans FT)	Notre modèle	Seuil validation	Seuil excellence
CER	13.77%	5.62% ✓	< 15%	< 8%
WER	42.41%	15.46% ✓	< 25%	< 15%
Needs review	16.20%	3.6% ✓	< 30%	< 20%

CER moyen

5.62%

Seuil excellence atteint

lignes testées

5 419

Test set scellé SHA-
256

IC Bootstrap 95%

[4.83%, 6.48%]

N = 1 000 ré-échantillonnages

Pipeline Bout en Bout : Images Gallica

Images Brutes

sans vérité terrain (pas de fichier XML , jsute l'image)

YOLO Layout (segmentation)


biglam/medieval-manuscript-yolov11n → MainZone, MarginTextZone

TrOCR fine-tuné


Transcription zone par zone → texte

PAGE XML + JSON

Coordonnées + transcriptions → livrable module
NLP



```
[
{
  "image": "/content/drive/MyDrive/projet_HTR/gallica_v2/images originales/btv1b55013464t_f141.jpg",
  "nb_zones": 100,
  "transcriptions": [
    {
      "zone_id": 0,
      "bbox": [
        1538,
        273,
        1009,
        118
      ],
      "class_name": "Defaultline",
      "texte": "n e metre en lieu ou il me uoie",
      "confidence": 0.9393834315890781,
      "char_confidences": [
        1.0,
        0.8706428408622742,
        0.7447935342788696,
        0.9614368081092834,
        0.9999552965164185,
        0.9999792575836182,
        0.9999234676361084,
        0.9999997615814209,
        0.9999302625656128,
        0.9998993873596191,
        0.6689109802246094,
        0.999762237071991,
        0.9999861717224121,
        0.9997250437736511
      ],
      "needs_review": false
    },
    {
      "zone_id": 1,
      "bbox": [
        307,
        273,
        868,
        115
      ],
      "class_name": "Defaultline",
      "texte": "si me sui mors a mes mains",
      "confidence": 0.9690337822611612,
      "char_confidences": [
        0.9999998807907104,
        0.9787771105766296,
        0.9999747276306152,
        0.99982750415802,
        0.9959661960601807,
        0.9999578124018212
      ]
    }
  ]
}
```



Volet 2 - NLP

Normalisation

Règles

Abréviation	Exemple	Résultat
Tilde nasale	grāt	grant
q̃ spécifique	q̃	que
Symbole g	gme	comme
Symbole p	p dieu	par dieu
u/v et i/j	uenir, ioie	venir, joie

Approche : Table de règles (baseline) → CamemBERT-LoRA pour les cas résiduels (prévu)

Limitation : Certaines abréviations sont ambiguës selon le contexte , les règles ne couvrent pas tous les cas

```
[
  {
    "document_id": "btvlb55013464t_f141",
    "zone_id": 0,
    "texte_brut": "n e metre en lieu ou il me uoie",
    "texte_normalise": "n e metre en lieu ou il me voie",
    "ambiguites": [],
    "confidence_htr": 0.9393834315890781,
    "needs_review_htr": false,
    "a_relire": false
  },
  {
    "document_id": "btvlb55013464t_f141",
    "zone_id": 1,
    "texte_brut": "7 si me sui mors a mes mains",
    "texte_normalise": "et si me sui mors a mes mains",
    "ambiguites": [],
    "confidence_htr": 0.9690337822611612,
    "needs_review_htr": false,
    "a_relire": false
  },
  {
    "document_id": "btvlb55013464t_f141",
    "zone_id": 2,
    "texte_brut": "a mon pere ce est du mains",
    "texte_normalise": "a mon pere ce est du mains",
```

Sortie : corpus_normalise_taln.json – data contract pour le module NLP

NER / POS

NER: Approche :

- **Étape 1 :** Gazetier (faible supervision)
Liste de noms construite manuellement sur le corpus réel
→ baseline rapide
 - **Étape 2 :** CamemBERT-LoRA
Entraîné sur les annotations du gazetier → généralise aux entités inconnues
- POS & lemmatisation**
- Chaque mot étiqueté avec sa nature grammaticale (NOUN, VERB, DET...) et son lemme
- Outil : stanza (français moderne) – dégradé assumé ;
pie_extended (modèle freem, moyen français) aurait été idéal mais incompatible avec l'environnement
- **Export :** corpus_ner.conll (CoNLL-2003) – NER + POS réunis, prêt pour TEI-XML

Limitation : Gazetier = liste fermée , ne détecte que les entités déjà connues. CamemBERT-LoRA nécessaire pour généraliser


✓ 200 lignes annotées par gazetier (faible supervision)
13 tokens étiquetés comme entité (avant validation manuelle)

Exemples d'entités trouvées :

mabile	→ B-PER	(ligne btv1b55013464t_f143_z6)
dame	→ B-TITLE	(ligne btv1b55013464t_f143_z15)
dame	→ B-TITLE	(ligne btv1b55013464t_f143_z25)
mabile	→ B-PER	(ligne btv1b55013464t_f143_z31)
fouch	→ B-PER	(ligne btv1b55013464t_f143_z36)
mabile	→ B-PER	(ligne btv1b55013464t_f143_z52)
mabile	→ B-PER	(ligne btv1b55013464t_f143_z60)
sire	→ B-TITLE	(ligne btv1b55013464t_f143_z65)
dame	→ B-TITLE	(ligne btv1b55013464t_f143_z65)
tiece	→ B-PER	(ligne btv1b55013464t_f143_z65)
mabile	→ B-PER	(ligne btv1b55013464t_f143_z83)
tiece	→ B-PER	(ligne btv1b55013464t_f143_z94)
dame	→ B-TITLE	(ligne btv1b55013464t_f143_z96)

metre	POS=NOUN	lemme=metre	NER=0
en	POS=ADP	lemme=en	NER=0
lieu	POS=NOUN	lemme=lieu	NER=0
ou	POS=CCONJ	lemme=ou	NER=0
il	POS=PRON	lemme=lui	NER=0
me	POS=PRON	lemme=moi	NER=0
voie	POS=VERB	lemme=voie	NER=0

Extraction de relations & Validation



Relations extraites :


(tiece, porte_titre, dame) conf=0.85

Méthode: co-occurrence avec contrainte de proximité textuelle (le titre doit être directement adjacent au nom, ≤ 2 caractères de distance)

Limitation : corpus narratif en vers $\rightarrow$ peu de relations explicites (contrairement à un corpus administratif qui en produirait davantage)

Graphe de connaissances & Export TEI-XML

- 4 personnages identifiés, 1 relation extraite et **validée**



- 1 fichier **XML** par page manuscrite
- Entités encodées en balises standard :
 <persName> (personnages), **<roleName>** (titres)
- Chaque mot annoté avec **POS + lemme**
- Validation XML automatique

```
<?xml version='1.0' encoding='UTF-8'?>
<TEI xmlns="http://www.tei-c.org/ns/1.0">
  <text>
    <body>
      <div type="acte">
        <p>
          <lb n="btv1b55013464t_f141_z0"/>
          <w pos="NOUN" lemma="n">n</w>
          <w pos="SYM" lemma="e">e</w>
          <w pos="NOUN" lemma="metre">metre</w>
          <w pos="ADP" lemma="en">en</w>
          <w pos="NOUN" lemma="lieu">lieu</w>
          <w pos="CCONJ" lemma="ou">ou</w>
          <w pos="PRON" lemma="lui">il</w>
          <w pos="PRON" lemma="moi">me</w>
          <w pos="VERB" lemma="voie">voie</w>
          <lb n="btv1b55013464t_f141_z1"/>
          <w pos="CCONJ" lemma="et">et</w>
          <w pos="SCONJ" lemma="si">si</w>
          <w pos="PRON" lemma="moi">me</w>
          <w pos="VERB" lemma="suivre">sui</w>
          <w pos="NOUN" lemma="mors">mors</w>
          <w pos="VERB" lemma="avoir">a</w>
          <w pos="DET" lemma="son">mes</w>
          <w pos="NOUN" lemma="main">mains</w>
        </p>
      </div>
    </body>
  </text>
</TEI>
```


Limitations & Plan pour les 2 semaines

Limites ou inconvénient

- **Corpus déséquilibré** : XIIIe – XVe s. (13^e – 15), peu de données sur le 14e.

Plan — 2 semaines restantes

- Publier le modèle sur HuggingFace
- Finaliser GitHub
- Amélioration par rapport aux remarques
- Rédiger l'article après les corrections



Merci
